

...

# FORMATION



MODULE 4:

# PERSPECTIVES FUTURES ET ÉTHIQUE DE L'IA GENERATIVE

N. Janvier AHOUANSOU,  
Ing. Sécurité Informatique  
Auditeur qualifié GPSE

PARTENAIRES





# PLAN

## Introduction

1. Tendances 2026 : AI vs. AI dans les guerres cyber
2. Éthique OWASP : Biais dans les modèles IA et régulations
3. Roadmap personnel : Intégrer l'IA dans les audits sécurité

## Questions / Réponses

## Conclusion



# ... INTRODUCTION



L'IA est devenue une force sismique transformant tous les secteurs essentiels de la vie: industrie, communication, recherche, santé, finance, sécurité, ...

Malgré l'opportunité relative qu'apporte l'IA, des préoccupations persistes: le **biais algorithmique**, la **désinformation à grande échelle**, la **perte de contrôle sur les décisions**; la **maîtrise de la qualité des données**, les **données synthétiques**, et la **redéfinition même de ce qu'est le travail humain**.

**Quel sera le futur de ce nouveau monde sans repère éthique ni socle réglementaire solide, où la capacité d'un modèle peut être utiliser à la fois pour attaquer et pour se défendre ?**

•••

# La présentation de ce jour, à l'occasion de la formation OWASP traitera des « Perspectives futures: éthique et Régulation de l'IA ».

Nous parlerons :

- Des tendances 2026 de l'IA;
- L'**Éthique** : Qui doit définir les principes moraux de l'IA ? Comment intégrer la *valeur humaine* au cœur du code ?
- La **Régulation** : Quelle est la place des législateurs ? (comme l'**AI Act** en Europe, et les initiatives dans le reste du monde). »
- De roadmap personnel « feuille de route personnelle » pour les acteurs des fonctions IT

# 1. Tendances 2026 : AI vs AI dans les guerres cyber

Les mois à venir verront émerger plusieurs tendances dans l'usage et le recours à l'IA soit sous une forme défensive ou offensive.

Déjà, les présentations ont montré que les cyberattaques ne sont plus seulement automatisées : elles deviennent **cognitives**, orchestrées par des IA capables de planifier, d'apprendre et de s'adapter à des changements.

En réponse aux usages offensifs, les défenses utilisent aussi des IA au plan éthique pour contrer les agissements des, créant un **champ de bataille numérique où les deux camps apprennent l'un de l'autre en temps réel**

### ••• ☐ : Adaptation des attaques pilotées par IA

- Attaques testant automatiquement plusieurs stratégies jusqu'à trouver une vulnérabilité à exploiter.
- Systèmes capables d'analyser les patchs et les signatures des mesures de sécurité déployées.
- IA multimodales utilisée pour exploiter les erreurs humaines (hameçonnage vocal, visuel, textuel).

Les IA offensives génèrent des **attaques entièrement sur mesure**, basées sur une modélisation comportementale du système ciblé.



### ☐ Autonomisation de la cyber défensive (AI Blue Team)



- Systèmes de détection avec **analyse comportementale continue**.
- IA capables de **neutraliser** certains vecteurs d'attaque.

Réponse dynamique : isoler des machines, reconfigurer des réseaux, limiter des priviléges.

Les SOC devront adopter des agents IA pour :

- Une surveillance continue;
- Une corrélation des milliers d'indicateurs
- réagissent en temps réel
- Mettre en place une politique dynamique en fonction des nouvelles données (CVE, ...)

## □ Désinformation automatisée et contreattaques IA

- . Deepfakes multi-modaux (voix + vidéo + documents) qui va se performer;
- . Génération massive de faux contenus ciblés
- . Détection automatisée par IA spécialisée (analyse de source, watermarking, cohérence sémantique).

## □ Montée des “agents cyber autonomes” →

- . scanning autonome de vulnérabilités,
- . cartographie automatique d'infrastructures,
- . coordination entre agents;
- . simulation de scénarios cyber anticipatifs.

La plateforme **NodeZero** (de Horizon3.ai) utilise déjà l'IA pour aller au-delà du simple scanning. Après l'identification de vulnérabilité, l'agent IA **détermine de manière autonome comment l'exploiter** et planifie une **chaîne d'attaque** pour évaluer le véritable impact sur le réseau. La criticité de l'impact n'est plus seulement appréciée par rapport au CVSS mais réellement

## ... □Convergence IA-IoT-cyber pour faire des attaques physiques

L'IA rend possibles :

- attaques sur infrastructures critiques,
- manipulations de capteurs ou de flux industriels,
- intrusions dans systèmes autonomes (drones, robots).

Les défenses intègrent donc des modèles IA spécialisés dans :

- la détection d'anomalies physiques,
- la protection des infrastructures OT (Operational Technology).

**Ver Stuxnet en 2010, sur les installations nucléaires iraniennes, qui depuis le réseau l'attaque classique se propage à l'API de l'automate industriel de traitement de l'eau créant sa destruction physique**

## □Course mondiale à l'IA défensive souveraine →

Au niveau État, ils renforcent leurs :

- capacités de cybersécurité nationale (CERT, CSIRT, SOC, ),
- cloud souverains sécurisés,
- IA de détection stratégique,
- unités militaires hybrides : cyber + IA.

Au plan régional, des organisations citoyennes travaillent déjà à la souveraineté des données traitées via les cloud et la collecte excessive des données par les outils d'IA

## ••• 2. Éthique OWASP : Biais dans les modèles IA et régulations →

Les enjeux éthique et réglementaire de l'AI cyber soulèvent des problématiques diversifiées.

Au plan éthique, il se pose souvent la question de:

- Existe-t-il un organe de contrôle l'autonomie des IA offensives / défensives ?
- Comment éviter l'emballement algorithmiques dans les conflits ?
- Quelle responsabilité en cas d'escalade provoquée par une IA mal alignée ?

Sur le plan légal, réglementaire et normatif:

- Quelles normes internationales traitent de l'autonomie cyber,
- La transparence des systèmes défensifs, le principe de l'auditabilité, de traçabilité,
- L'obligation de faire superviser par l'homme ("Human in the Loop").

## ••• 2. 1. Éthique OWASP : Biais dans les modèles IA



Depuis 2023, l'association caritative « Open Worldwide Application Security Project » a élaboré un guide pour la sécurité des applications utilisant les modèles LLM et les modèles d'IA nommé « OWASP Top 10 for LLM applications et OWASP AI Security & Privacy guide ».

Le guide traite de:

- Risques propres aux modèles d'IA (intrusions, exfiltration, manipulations).
- Biais, la partialité et les discriminations générées par les modèles.
- Les risques systémiques (désinformation, sécurité, conformité réglementaire



## □ D'où proviennent les biais pour l'IA



### Biais des données

Sous-représentation de données de cultures, de genres, de langues.

Données historiques déjà discriminantes.

Déséquilibre dans les sources d'information.

### Biais de conception du modèle

Choix des paramètres d'entraînement.

Architecture favorisant certaines corrélations.

Approches d'évaluation insuffisantes.

### Biais d'usage

Déploiement dans un contexte différent de celui envisagé.

Mauvaise interprétation des sorties du modèle.

Entrées manipulées par des utilisateurs malveillants (prompt injection, jailbreaking).



## □ Risques liés aux biais (OWASP TOP 10 FOR LLM)



Les biais dans les modèles de l'IA sont à la fois sources de risques éthiques et de cybersécurité.

- Les biais peuvent conduire à des réponses biaisées ou toxiques (**LLM07 : Insecure Output Handling** ).
- récupération et réutilisation de modèles biaisés (**LLM10: Model Theft** )
- Injection volontaire de biais par des attaquants (**LLM04 : Training Data Poisoning**)

# ••• □Approches de OWASP pour atténuer les biais et les risques y relatifs



## Gouvernance des données

- . Documentation complète (datasheet).
- . Vérification de représentativité des datasets.
- . Audit continu des sources.

## Robustesse du modèle

- . Tests adversariaux pour identifier des biais cachés.
- . Évaluation continue par groupes de population.
- . Normalisation et balancement automatique.

## Monitoring post-déploiement

- . Système de détection d'anomalies ou de dérive.
- . Logs des interactions sensibles.
- . Alertes en cas de comportements biaisés.

## Transparence

- . Indication claire des limites.
- . Explicabilité des processus de décision.
- . Inclusion d'un "AI Ethics Impact Statement".

## ... 2. 2. Régulation de l'IA



### Niveau EU AI Act (2024–2026)

Il reste un cadre structurant qui:

Obligations pour les modèles IA à risque :

- Documentation des données.
- Robustesse et cybersécurité.
- Gouvernance des biais.
- Auditabilité + enregistrement des événements.
- Transparence envers les utilisateurs.
- Interdiction de certains usages (surveillance biométrique massive, manipulation cognitive).

□ Les modèles de fondation doivent :

- publier des résumés de données d'entraînement,
- respecter les droits d'auteur,
- intégrer des garde-fous anti-manipulations

OCDE, UNESCO, ISO

OCDE – AI Principles

Normes internationales de référence.  
Mots clés : équité, transparence, responsabilité, sécurité, droits humains.

UNESCO – Éthique de l'IA

Cadre global basé sur droits humains et inclusion culturelle.

ISO/IEC 42001 (2023–2025)

Gestion de la gouvernance IA (gestion des risques, conformité, qualité, traçabilité)

# ••• Alignement avec OWASP : la triade éthique



## 1. Sécurité

Le modèle ne doit pas causer de dommages (involontaires ou via attaques).

## 2. Robustesse

Le modèle doit fonctionner correctement et de façon équitable.

## 3. Transparence & responsabilité

Toute décision ou recommandation IA doit pouvoir être expliquée, tracée, auditee

### ••• 3. Roadmap personnel : Intégrer l'IA dans les audits sécurité →



En 2026, ce dispositif modulaire doit servir de référence pour les l'ajustement des compétences.  
6 à 12 mois de formation selon le niveau

Roadmap personnel est mis en place et pensé pour accompagner la formation et le recyclage des experts en sécurité:  
auditeur,  
pentester,  
risk analyst,  
Membre de SOC et SOC  
Responsable de risque IA

1

## Foundations : Comprendre l'IA appliquée au cyber

**Objectif :** acquérir les bases techniques indispensables.

**Compétences à développer**

- LLM, embeddings, vector stores, agents IA.
- Comprendre les risques spécifiques LLM (OWASP Top 10 LLM).
- Différents usages de l'IA en sécurité :
  - détection, corrélation d'événements, analyse de logs,
  - classification d'incidents,
  - simulation de menaces non techniques (phishing, social engineering IA).

2

## Outils IA pour Auditeurs : Maîtrise pratique

**IA généralistes (pour automatiser l'analyse)**

- ChatGPT / Claude / Mistral / Llama
- Extensions VSCode IA pour revue de code

**IA spécialisées sécurité**

- Analyse de logs automatisée (Elastic + IA, Splunk AI Assist)
- Darktrace, Vectra, Microsoft Defender AI
- Analyse IA de configuration Cloud (Wiz, Lacework, Prisma, OrcaAI)
- **IA pour automatiser les tâches d'audit**
- Génération de checklist IA (ISO 27001, NIST, OWASP)
- Analyse automatique de politiques de sécurité

3

## ... Automatisation : Construire tes assistants IA d'audit

### Compétences à développer

- Prompts avancés (audit, risk, analyse de logs)
- Construction d'agents IA spécialisés : “Audit Assistant”, “Log Analyzer Bot”
- Pipelines IA + outils : Python + API d'IA + SIEM/SOAR
- Détection d'anomalies sur données anonymisées
- Analyse d'architecture via IA

4

## Méthodologies : IA + Cadres de conformité →

### Adapter l'audit à l'ère de l'IA

- Intégration IA dans un audit ISO 27001 / 27005
- Cartographie des risques IA → cybersécurité → conformité
- Audit LLM et IA selon : OWASP LLM Top 10, NIST AI RMF, EU AI Act

### Projets pratiques

- Construire une **checklist IA & Sécurité** pour ton entreprise.
- Réaliser un **audit pilote IA d'une application interne**.

## Compétences clés

- Mesure continue de l'efficacité IA dans la sécurité
- Détection de dérive (model drift, data drift)
- Surveillance de l'usage interne de l'IA (Shadow AI)
- Évaluation : hallucinations, biais, exposition involontaire à des données sensibles.

## Objectif final

Transformer le rôle d'auditeur en **superviseur continu des risques IA & sécurité**

## Leadership & Impact (en continu)

### Devenir un référent IA dans la sécurité

- Présenter l'approche IA lors d'audits internes.
- Former les équipes (SOC, dev, GRC).
- Mettre en place un **cadre d'usage responsable de l'IA**.
- Participer aux communautés (OWASP AI, NIST, ISO).

Ton objectif : **automatiser, améliorer et fiabiliser les audits sécurité via l'IA.**

Rôle final : **Auditeur IA-Sécurité moderne**, capable d'évaluer autant les systèmes classiques que les systèmes d'IA.

# CONCLUSION

...



- 2026 est l'année où l'IA devient un acteur stratégique à part entière, capable de défendre, d'attaquer, de tromper ou de neutraliser.
- Le défi pour les organisations et les États est de garder le **contrôle humain, anticiper l'escalade et renforcer les défenses éthiques et robustes.**
- Le défi pour les RSSI, RSI, DPO sera de se référer des pratiques de énoncées par:
  - **OWASP:** Les biais sont un risque stratégique à traiter les vulnérabilités; ce qui met un accent sur le choix de modèles et le traitement des données d'apprentissage (ETL).
  - **OWASP recommandée :** Conception éthique dès le départ. Sécurité + intégrité des données. Évaluation indépendante. Transparence et documentation systématique. Supervision humaine
  - **AI Act, NIST2, ISO:** obligation d'audit, de traçabilité et de gouvernance.
  - **CN:** Sans être une réglementation spécifique de l'AI, demeure applicable aux projets IA



# QUESTIONS / REONSES